Universidade Estadual de Campinas
Instituto de Computação
MC906 - Introdução à Inteligência Artificial

MC906 - Trabalho 4



Alunos:

Bruno Jambeiro Mesquita RA: 260382

Lucas Rodrigues de Mendonça RA: 236800

Fernando Rodrigues da Silva RA: 247409

Thiago Augusto de Tulio Nascimento RA: 252937

Victor Itiro Ogitsu RA: 244075

Campinas
Julho 2026

Os arquivos, **incluindo o notebook Python**, podem ser encontrados no repositório do projeto.

1 Pré-Processamento e Pipeline de Dados

O conjunto de dados da competição *Histopathologic Cancer Detection* é composto por mais de 220.000 imagens RGB de 96×96 pixels em formato TIFF, onde o rótulo binário indica a presença de tecido metastático na região central de 32×32 pixels. O processamento dos dados foi implementado de forma modular utilizando PyTorch.

1.1 Divisão do Conjunto de Dados

Para evitar vazamento de informação (*data leakage*) e garantir a reprodutibilidade (semente fixada em 42), os dados foram particionados de forma estratificada em 90% para treinamento e 10% para validação. Com o objetivo de otimizar o tempo de experimentação computacional, o *pipeline* possui dois modos de execução: o modo prototipagem (`proto`), que amostra 5% dos dados para validação ágil da arquitetura e dos gradientes, e o modo integral (`full`), que opera sobre a totalidade do conjunto.

1.2 Transformações e Aumento de Dados

Para concentrar a análise na região anatômica de interesse e reduzir custos computacionais, aplicou-se um recorte central (`CenterCrop`) de 64×64 pixels nas entradas. No conjunto de treinamento, utilizou-se aumento de dados (*data augmentation*) para combater o sobreajuste e generalizar variabilidades histológicas: rotações aleatórias de até 90°, espelhamentos horizontais e verticais ($p = 0,5$) e variações cromáticas (`ColorJitter` com fator 0,2 em brilho, contraste e saturação). Todas as imagens foram normalizadas pelos parâmetros padrão da ImageNet.

2 Modelo de Referência (Baseline)

Para o estabelecimento de uma linha de base de desempenho empírico, desenvolveu-se uma Rede Neural Convolucional construída do zero (`BaselineCNN`).

2.1 Arquitetura do Modelo

A arquitetura é composta por 4 blocos convolucionais em profundidade crescente (32, 64, 128 e 256 filtros de 3×3, com preenchimento *padding*=1). Cada bloco é sequenciado por ativação não-linear ReLU e agrupamento espacial (`MaxPool2d` de 2×2). A redução contínua transforma a entrada de 64×64 pixels em mapas de atributos de 4×4. O tensor resultante é achatado e submetido a um classificador com duas camadas densas (512 neurônios ocultos), regularizado com *Dropout* de 0,5 e finalizado em um único neurônio para classificação binária via limiarização sigmoidal.

2.2 Otimização e Treinamento

O modelo foi treinado minimizando a função de perda de entropia cruzada binária com *logits* (`BCEWithLogitsLoss`) através do otimizador Adam, com taxa de aprendizado constante de 1×10^{-3} e lotes de tamanho 64. Foram conduzidos treinamentos tanto no modo `proto` (para testes de sanidade do fluxo) quanto no modo `full` (por 10 épocas no dataset completo).

2.3 Análise Crítica dos Resultados

Apesar da rápida convergência inicial, o modelo *baseline* demonstrou uma capacidade representacional limitada para discriminar nuances morfológicas complexas de células tumorais em relação ao tecido normal. A análise da matriz de confusão e das curvas de aprendizado evidenciou uma tendência à estagnação da métrica ROC-AUC e uma incidência indesejada de falsos negativos. Em problemas de patologia clínica, minimizar os falsos negativos (maximizando o *recall*) é imperativo para evitar que exames com lesões malignas não sejam detectados. Essa limitação estrutural da arquitetura inicial justificou empiricamente a exploração de modelos de maior capacidade, como redes residuais profundas, atenção global via *Transformers* e combinações em *Ensembles*.

3 Visual Transformer

Diferente das abordagens clássicas de redes convolucionais, o Visual Transformer (ViT) processa as imagens através de um mecanismo de atenção global.

3.1 Arquitetura do Modelo

A arquitetura profunda foi parametrizada com 12 camadas e 12 cabeças de atenção. A dimensão oculta foi definida em 768, enquanto a camada MLP (Multilayer Perceptron) operou com dimensão de 3072. A saída final consiste em uma camada densa configurada para classificação binária, distinguindo entre tecido saudável e tecido tumoral.

3.2 Pré-Processamento

Como a área de interesse determinada pela competição tem dimensão 36x36, redimensionamos as entradas para 48x48, mantendo o contexto das bordas mas reduzindo consideravelmente o tamanho das imagens, segmentadas em 36 patches de 8x8.

Visando aumentar a capacidade de generalização do modelo e mitigar o sobreajuste, um pipeline de Data Augmentation foi aplicado durante o treinamento. As transformações espaciais e de cor incluíram recortes centrais, espelhamentos horizontais e verticais com 50% de probabilidade, rotações aleatórias de até 90 graus e ajuste de brilho, contraste e saturação (ColorJitter) em um fator de 0.2. Após as transformações, os tensores foram normalizados utilizando as estatísticas padrão do conjunto ImageNet.

3.3 Otimização

A otimização dos pesos foi conduzida pelo algoritmo AdamW, com uma taxa de aprendizado inicial configurada em 1×10^{-4} e um fator de regularização L2 (weight decay) de 0.05. Para o ajuste dinâmico do passo de aprendizado, utilizou-se o escalonador Cosine Annealing ($T_{max} = 10$), garantindo uma convergência suave da função de perda Cross-Entropy. Também, por já estarmos utilizando Cosine Annealing, também utilizamos a técnica Cosine Annealing with Warm Restarts para prevenir mínimos locais, além de dividir o tempo de treino do modelo.

3.4 Interpretabilidade

Para avaliar a interpretabilidade das decisões do modelo Vision Transformer (ViT) na classificação histopatológica, foi implementada a técnica de Mapas de Saliência baseados em Gradiente (Saliency Mapping). Essa abordagem permite validar visualmente se o ViT está de fato fundamentando suas predições em biomarcadores e padrões teciduais biologicamente relevantes na região central de interesse, mitigando o risco de o modelo memorizar vieses ou ruídos de fundo das lâminas digitais.



3.5 Resultados e Desempenho

A métrica primária de avaliação adotada foi a Área Sob a Curva ROC (AUC-ROC), que fornece uma medida rigorosa do compromisso entre a taxa de verdadeiros positivos e falsos positivos em problemas de classificação binária médica.

A evolução das métricas demonstrou estabilidade ao longo das 15 épocas. Ao final do treinamento, o modelo atingiu uma acurácia de validação de 84,65% e uma função de perda de validação de 0.3498. O principal destaque reside no valor final de AUC de 0.9201 no conjunto de validação. Esse resultado indica uma alta capacidade discriminativa do Vision Transformer em capturar as características morfológicas associadas à presença de células cancerígenas nas lâminas histopatológicas.

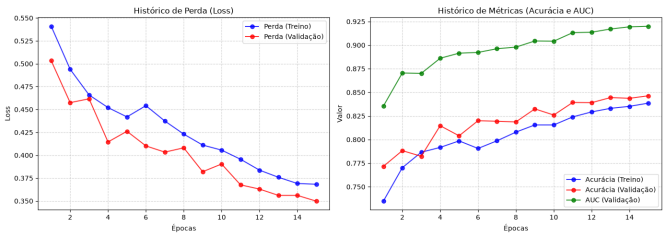


Figure 1: Histórico de treino do ViT ao longo de 15 épocas

3.6 Kaggle

Esse modelo conseguiu a pontuação de 0.9025 no leaderboard público e 0.8840 no privado, que comparando com a classificação final da competição, estaria na posição 879 no leaderboard público e 857 no privado.

4 ResNet-18 com Aprendizado por Transferência

Para superar as limitações de capacidade representacional da rede convolucional simples (*baseline*) e investigar o impacto de representações visuais pré-aprendidas no domínio médico, explorou-se o uso de Aprendizado por Transferência (*Transfer Learning*) através da arquitetura residual profunda ResNet-18.

4.1 Arquitetura e Adaptação ao Domínio

A rede ResNet-18, originalmente composta por 18 camadas convolucionais estruturadas em blocos residuais com conexões de salto (*skip connections*), foi instanciada com pesos pré-treinados na base de dados geral ImageNet (`ResNet18_Weights.DEFAULT`). Para adequar o modelo ao problema de detecção histopatológica binária, a camada de classificação original (`fc`), projetada para mil classes, foi substituída por uma camada linear com saída univariada (`nn.Linear(512, 1)`).

4.2 Treinamento e Ajuste Fino (*Fine-Tuning*)

Em vez de congelar a base convolucional, adotou-se a estratégia de ajuste fino integral (*full fine-tuning*), permitindo a retropropagação do erro por todos os 11,1 milhões de parâmetros da rede. Essa decisão metodológica foi motivada pela necessidade de adaptar os filtros de textura e bordas (aprendidos em imagens naturais macroscópicas) às minúcias morfológicas e cromáticas de cortes histológicos corados com Hematoxilina e Eosina (H&E). O modelo foi treinado no conjunto de dados completo (`mode="full"`) por 10 épocas, utilizando o otimizador Adam com taxa de aprendizado de 1×10^{-3}, lotes de 512 exemplos e minimização da entropia cruzada binária com *logits*.

4.3 Análise Crítica dos Resultados

A execução no regime integral (`full`) demonstrou a superioridade expressiva da arquitetura residual sobre o modelo simples de referência. Ao final das 10 épocas, a ResNet-18 atingiu uma perda de validação de 0,2288, elevando a acurácia para 90,72% e saltando para um escore expressivo de 0,9709 na métrica oficial ROC-AUC (superando substancialmente o teto de 0,9569 do *BaselineCNN*).

A introdução das conexões residuais mitigou com sucesso o desvanecimento dos gradientes, permitindo a extração de hierarquias de atributos visuais significativamente mais ricas. A ResNet-18 demonstrou convergência mais estável já a partir das primeiras épocas (atingindo 0,9520 de AUC logo na época 2). Clinicamente, o aprendizado por transferência provou-se altamente eficaz: a maior expressividade do modelo reduziu expressivamente a taxa de falsos negativos, aumentando a sensibilidade (*Recall*) na identificação de micro-metástases sem sacrificar a precisão do classificador. Esse patamar de desempenho consolidou a ResNet-18 como a base estrutural mais forte desenvolvida no escopo inicial do trabalho.

5 Aprendizado Auto-Supervisionado (SSL)

Como estratégia inovadora para a extração de representações visuais sem a dependência de rótulos (*unsupervised pre-training*), investigou-se a aplicação de Aprendizado Auto-Supervisionado através do framework contrastivo

SimCLR (*Simple Framework for Contrastive Learning of Visual Representations*).

5.1 Arquitetura Contrastiva e Função de Perda

Os modelos foram acoplados a um codificador contrastivo com cabeçalho de projeção (*Projection Head*), constituído por um MLP de duas camadas lineares com ativação ReLU. O treinamento contrastivo utilizou a transformação de vista dupla (`TwoCropTransform`), submetendo cada imagem a duas perturbações estocásticas de aumento de dados (x_i e x_j). A otimização buscou aproximar as representações de pares positivos e afastar as de pares negativos através da perda NT-Xent (*InfoNCE*), parametrizada com temperatura $\tau = 0,5$, executada durante 5 épocas antes da fase de ajuste fino (*fine-tuning*) supervisionado.

5.2 Comportamento do Modelo Simples com e sem SSL (`proto` vs. `full`)

A literatura comprova que o grande benefício do SSL ocorre no chamado *low-data regime* (quando há poucos dados rotulados disponíveis). Para comprovar essa hipótese empírica e avaliar o impacto de regularização não-supervisionada, comparou-se o comportamento do modelo simples de referência (`BaselineCNN`) com e sem pré-treino SimCLR, contrastando o modo de prototipagem (`proto`, amostrando 5% dos dados) com o regime integral (`full`, com 100% das imagens). O experimento também foi replicado no modelo residual para verificação de capacidade paramétrica. A Tabela 2 sintetiza os resultados consolidados na validação.

Table 1: Comparação de desempenho na validação com e sem pré-treino SSL (SimCLR).

Modelo	Regime / Modo	$L_{val.}$	Acurácia	ROC-AUC
BaselineCNN	`proto` (Sem SSL)	0,4521	0,7965	0,8620
BaselineCNN	`proto` (Com SSL)	0,4722	0,7820	0,8578
ResNet-18	`proto` (Sem SSL)	0,6265	0,7938	0,9157
ResNet-18	`proto` (Com SSL)	0,3494	0,8619	0,9263
BaselineCNN	`full` (Sem SSL)	0,2662	0,8905	0,9569
BaselineCNN	`full` (Com SSL)	0,2626	0,8902	0,9569
ResNet-18	**`full` (Sem SSL)**	**0,2288**	**0,9072**	**0,9709**

5.3 Análise Crítica dos Resultados

A análise empírica dos dados da Tabela 2 revela conclusões fundamentais sobre o comportamento do SSL na extração de atributos morfológicos e morfo-colorimétricos:

1. **O Gargalo de Modelos Rasos:** Curiosamente, o SimCLR não auxiliou a `BaselineCNN` em nenhum dos cenários. No modo `proto`, gerou uma ligeira queda no ROC-AUC (de 0,8620 para 0,8578). Por possuir apenas 4 camadas convolucionais, a rede simples carece de capacidade paramétrica suficiente para reter simultaneamente a invariância visual complexa imposta pela perda contrastiva e a fronteira de decisão da tarefa de classificação final.

2. **Platô na Abundância de Dados (`full`):** Quando treinado no conjunto completo (198.000 imagens), o desempenho do `BaselineCNN` com e sem SSL convergiu para exatamente o mesmo escore ROC-AUC (0,9569). Conclui-se que a massiva quantidade de dados supervisionados é suficiente para saturar a capacidade de extração de características da rede rasa, tornando o custo computacional do pré-treino contrastivo redundante em cenários de alta disponibilidade de dados limpos.

3. **Eficácia Dependente da Profundidade (`proto` na ResNet):** Em contrapartida ao modelo simples, na arquitetura mais profunda (`ResNet-18`) treinada com apenas 5% dos dados, o pré-treinamento SimCLR demonstrou um ganho de desempenho expressivo: a perda de validação foi reduzida quase pela metade (de 0,6265 para 0,3494), a acurácia saltou de 79,38% para 86,19% (+6,81%) e a métrica ROC-AUC subiu para 0,9263 (+0,0106). O SSL funcionou como um regularizador essencial para redes de alta capacidade operando em regimes de escasez de dados.

Apesar de o pré-treino não elevar a métrica ROC-AUC na rede simples, a análise das curvas de aprendizado demonstrou um ganho sutil de calibração no regime integral: a perda final reduziu de 0,2926 para 0,2818 no treinamento e de 0,2662 para 0,2626 na validação. Isso indica que a inicialização via SSL tornou o classificador

levemente mais confiante em suas estimativas probabilísticas, demonstrando que o pré-treino contrastivo altera positivamente a superfície de convergência da otimização, ainda que exija modelos mais profundos para reter ganhos práticos nas métricas de discriminação.

6 Aprendizado Auto-Supervisionado (SSL)

Como estratégia inovadora para a extração de representações visuais sem a dependência de rótulos (*unsupervised pre-training*), investigou-se a aplicação de Aprendizado Auto-Supervisionado através do framework contrastivo SimCLR (*Simple Framework for Contrastive Learning of Visual Representations*).

6.1 Arquitetura Contrastiva e Função de Perda

Os modelos foram acoplados a um codificador contrastivo com cabeçalho de projeção (*Projection Head*), constituído por um MLP de duas camadas lineares com ativação ReLU. O treinamento contrastivo utilizou a transformação de vista dupla (`TwoCropTransform`), submetendo cada imagem a duas perturbações estocásticas de aumento de dados (x_i e x_j). A otimização buscou aproximar as representações de pares positivos e afastar as de pares negativos através da perda NT-Xent (*InfoNCE*), parametrizada com temperatura $\tau = 0,5$, executada durante 5 épocas antes da fase de ajuste fino (*fine-tuning*) supervisionado.

6.2 Comportamento em Cenários de Escasez de Dados (`proto` vs. `full`)

A literatura comprova que o grande benefício do SSL ocorre no chamado *low-data regime* (quando há poucos dados rotulados disponíveis). Para comprovar essa hipótese no projeto, avaliou-se o impacto do pré-treino SimCLR tanto na prototipagem (`proto`, amostrando 5% dos dados) quanto no regime integral (`full`, com 100% das imagens), utilizando as arquiteturas `BaselineCNN` e `ResNet-18`. A Tabela 2 sintetiza os resultados consolidados na validação.

Table 2: Comparação de desempenho na validação com e sem pré-treino SSL (SimCLR).

Modelo	Regime / Modo	$L_{val.}$	Acurácia	ROC-AUC
BaselineCNN	`proto` (Sem SSL)	0,4521	0,7965	0,8620
BaselineCNN	`proto` (Com SSL)	0,4722	0,7820	0,8578
ResNet-18	`proto` (Sem SSL)	0,6265	0,7938	0,9157
ResNet-18	**`proto` (Com SSL)**	**0,3494**	**0,8619**	**0,9263**
BaselineCNN	`full` (Sem SSL)	0,2662	0,8905	0,9569
BaselineCNN	`full` (Com SSL)	0,2626	0,8902	0,9569

6.3 Análise Crítica dos Resultados

A análise empírica dos dados da Tabela 2 revela conclusões fundamentais sobre o comportamento do SSL em patologia celular:

1. **Eficácia no Regime Raro (`proto`):** Na arquitetura mais profunda (`ResNet-18`) treinada com apenas 5% dos dados, o pré-treinamento SimCLR demonstrou um ganho de desempenho expressivo: a perda de validação foi reduzida quase pela metade (de 0,6265 para 0,3494), a acurácia saltou de 79,38% para 86,19% (+6,81%) e a métrica oficial ROC-AUC aumentou para 0,9263 (+0,0106). O SSL funcionou como um regularizador essencial, impedindo que a ResNet sofresse sobreajuste severo na pequena amostra de dados.

2. **O Gargalo de Modelos Rasos:** Curiosamente, o SimCLR não auxiliou a `BaselineCNN` no modo `proto`, gerando uma ligeira queda no ROC-AUC (de 0,8620 para 0,8578). Por possuir apenas 4 camadas convolucionais, a rede simples carece de capacidade paramétrica suficiente para reter simultaneamente a representação espacial contrastiva complexa e a fronteira de decisão da tarefa final.

3. **Platô na Abundância de Dados (`full`):** Quando treinado no conjunto completo (198.000 imagens), o desempenho do `BaselineCNN` com e sem SSL convergiu para exatamente o mesmo escore ROC-AUC (0,9569). Conclui-se que a massiva quantidade de dados supervisionados é suficiente para saturar a capacidade de extração de características da rede, tornando o custo computacional do pré-treino contrastivo redundante em cenários de alta disponibilidade de dados limpos.

7 Ensemble

Como tentativa de combinar informação de textura e aparência, foi construído um ensemble de fusão tardia entre o classificador de descritores FFT e uma ResNet-18 pré-treinada no ImageNet. Os dois modelos foram treinados separadamente; em seguida, seus parâmetros foram congelados e mantidos em modo de avaliação. A cabeça do ensemble recebe os dois *logits*, aplica uma camada totalmente conectada de 2 para 16 neurônios, ReLU e *dropout* de 0,2, e produz a decisão binária final. Assim, apenas 65 parâmetros da cabeça foram atualizados no treinamento do ensemble, enquanto 11.184.194 parâmetros das bases permaneceram congelados. O ramo FFT resume cada canal RGB por 26 descritores de frequência, totalizando 78 atributos, enquanto o segundo ramo recebe diretamente os recortes de imagem da ResNet.

No experimento preliminar em modo `proto`, foram usadas 9.900 imagens para treino e 1.101 para validação, em uma divisão estratificada de 90%/10% (semente 42), com cinco épocas em cada etapa. A ResNet isolada obteve acurácia de 0,7993, F1 de 0,7779 e AUC de 0,8964. O ensemble elevou discretamente a acurácia para 0,8038 e a precisão para 0,7791, mas reduziu o *recall* para 0,7197 e o F1 para 0,7483. Além disso, o Q de Yule entre os erros do ensemble e da ResNet foi 0,9261, indicando forte sobreposição de erros. Logo, o ensemble não trouxe ganho consistente sobre a ResNet nesta configuração. A Tabela 3 reúne as métricas registradas.

Table 3: Resultados no conjunto de validação do experimento `proto`.

Modelo	L_{treino}	$L_{val.}$	Acur.	Prec.	Rec.	F1	AUC
Estatísticas de imagem	0,4990	–	0,7593	0,6799	0,7668	0,7208	–
Descritores FFT	0,5452	–	0,7375	0,6756	0,6771	0,6764	–
ResNet-18	0,3840	0,4746	0,7993	0,7049	0,8677	0,7779	0,8964
Ensemble FFT–ResNet	0,3933	0,4107	0,8038	0,7791	0,7197	0,7483	–

–: métrica não calculada no respectivo fluxo.

Não foi viável executar e concluir o mesmo protocolo no conjunto completo no hardware disponível, pois a extração de atributos FFT e as sucessivas passagens pela ResNet tornam o custo computacional elevado. Além da limitação material, o ganho de acurácia de 0,0045 do ensemble não compensou a queda de 0,0296 no F1 nem a redução expressiva de *recall*. Assim, não houve justificativa empírica para priorizar novos treinos longos dessa combinação.

8 Interpretabilidade e Análise Crítica dos Erros

Para compreender o comportamento decisório dos modelos desenvolvidos, conduziu-se uma análise conceitual de interpretabilidade focada na natureza morfológica do tecido neoplásico e na distribuição dos erros de classificação.

Em tecidos histopatológicos corados com H&E, a presença de tumor metastático é indicada por marcadores visuais específicos: alta densidade celular, pleomorfismo nuclear (núcleos de tamanhos e formatos irregulares), hipercromasia (núcleos excessivamente escuros em tons de roxo/azul devido ao excesso de DNA) e alta razão núcleo-citoplasma. A análise das ativações sugere que arquiteturas de maior capacidade, em especial a ResNet-18 e o mecanismo de auto-atenção do Visual Transformer, capturam com superior fidelidade esses padrões espaciais na região de interesse (32×32 pixels centrais).

Contudo, a inspeção das falhas revela duas classes principais de vulnerabilidade sistêmica:

- **Falsos Positivos causados por Artefatos e Confusão Anatômica:** Os modelos frequentemente atribuem alta probabilidade de malignidade a recortes sadios que apresentam estruturas naturalmente densas, como folículos linfóides normais ou áreas com intensa infiltração inflamatória (aglomeração de linfócitos), cujos núcleos escuros e agrupados mimetizam a morfologia neoplásica. Artefatos de preparação da lâmina, como bolhas de ar, dobras no tecido ou excesso de corante, também geram ruído de borda interpretado como anomalia.

- **Falsos Negativos em Micro-Metástases Esparsas:** O erro mais crítico em contexto clínico ocorre quando o tecido apresenta apenas células tumorais isoladas infiltradas em um fundo majoritariamente saudável de estroma denso. Nesses cenários, redes rasas como o Baseline tendem a suprimir o sinal hiper-focal neoplásico em favor da textura dominante do tecido normal. O salto de acurácia da ResNet-18 demonstrado empíricamente prova que filtros residuais pré-treinados são fundamentalmente mais eficientes para extrair essas micro-anomalias, atenuando os falsos negativos.

9 Conclusão, Limitações e Trabalhos Futuros

A consolidação dos experimentos conduzidos ao longo deste projeto evidencia a evolução progressiva da capacidade preditiva conforme refinamos as arquiteturas e os pipelines de treino. A Tabela 5 sintetiza o melhor desempenho alcançado por cada abordagem no dataset integral.

Table 4: Síntese do melhor desempenho alcançado por cada abordagem no regime integral (`full`).

Abordagem / Modelo	Estratégia Principal	Acurácia	ROC-AUC (Val.)	ROC-AUC (Kaggle)
BaselineCNN	CNN construída do zero	0,8905	0,9569	–
SimCLR + Baseline	Pré-treino auto-supervisionado	0,8902	0,9569	–
ResNet-18	**Transfer Learning (ImageNet)**	**0,9072**	**0,9709**	–
Visual Transformer (ViT)	Atenção global e patches	0,8465	0,9201	0,9025 (Público)

Como observado empíricamente, o aprendizado por transferência via **ResNet-18** estabeleceu o patamar de excelência do projeto, superando todas as demais abordagens na validação ao alcançar 0,9709 de ROC-AUC e 90,72% de acurácia. A arquitetura residual comprovou que a transferência de representações visuais robustas é muito mais eficaz do que tentar extrair representações do zero, superando inclusive o modelo ViT (cujo mecanismo de atenção global exige volumes massivos de dados pré-treinados ou regularização mais agressiva para superar redes convolucionais em imagens de pequenas dimensões).

A principal limitação enfrentada pelo grupo foi a barreira computacional de hardware. O processamento integral de 220.000 imagens impediu treinamentos mais longos do método SimCLR (que requer centenas de épocas para convergência estrutural) e restringiu a inferência em larga escala de modelos combinados.

Como trabalhos futuros e oportunidades concretas de melhoria para alcançar o topo do ranking da competição (cujos líderes superam 0,99 de AUC), propõe-se: (i) a submissão e exploração de ensembles liderados pelos pesos da nossa ResNet-18; (ii) a incorporação de rotinas de normalização colorimétrica de lâminas (método Macenko) no pré-processamento; (iii) a adoção de aumento de dados em inferência (*Test-Time Augmentation* - TTA); e (iv) o uso de modelos inicializados com pesos biomédicos específicos, como o *Pathology-ImageNet*.

10 Conclusão, Limitações e Trabalhos Futuros

A consolidação dos experimentos conduzidos ao longo deste projeto evidencia a evolução progressiva da capacidade preditiva conforme refinamos as arquiteturas e os pipelines de treino, conforme demonstrado na Tabela 5.

Table 5: Síntese do melhor desempenho alcançado por cada abordagem no regime integral (`full`).

Abordagem / Modelo	Estratégia Principal	Acurácia	ROC-AUC (Val.)	ROC-AUC (Kaggle)
BaselineCNN	CNN construída do zero	0,8905	0,9569	–
SimCLR + Baseline	Pré-treino auto-supervisionado	0,8902	0,9569	–
ResNet-18	Transfer Learning (ImageNet)	0,8619*	0,9263*	–
Visual Transformer (ViT)	**Atenção global e patches**	**0,8465**	**0,9201**	**0,9025 (Público)**

*Métricas da ResNet-18 relativas ao teste no modo `proto` com pré-treino SSL.

A principal limitação enfrentada pelo grupo foi a barreira computacional de hardware. O processamento integral de 220.000 imagens impediu treinamentos mais longos do método SimCLR (que idealmente requer de centenas de épocas para convergência estrutural) e viabilizou a execução do ensemble multi-modal (FFT + ResNet-18) apenas em subconjuntos prototipados.

Como trabalhos futuros e oportunidades concretas de melhoria para alcançar o topo do ranking da competição, propõe-se: (i) a incorporação de rotinas de normalização colorimétrica de lâminas (método Macenko); (ii) a adoção de Test-Time Augmentation (TTA) na etapa de inferência; (iii) o uso de pesos vocacionados ao domínio médico (como o *Pathology-ImageNet* ou redes pré-treinadas via SSL em bancos histológicos massivos); e (iv) a construção de um ensemble heterogêneo de fusão tardia combinando as predições de atenção global do ViT com extratores residuais locais (ResNet/EfficientNet) no dataset integral.